

# ML2019Fall Final Project

## Domain Adaptation

R08921A08 廖子毅 R08942085 陳芃玟 R08942086 趙達軒


### - 簡介與動機

在這次期末專題中，我們選擇的題目為領域轉移 (Domain Adaptation)，其目標是希望利用有標籤的源域 (Source domain) 資料訓練好無標籤的目標域 (Target Domain) 資料。

關於期末主題 - 領域轉移，我們主要實作的方向有四點，分別為：資料前處理、源域與目標域的重疊、分類器的決定邊界改善以及偽標籤半監督式學習。

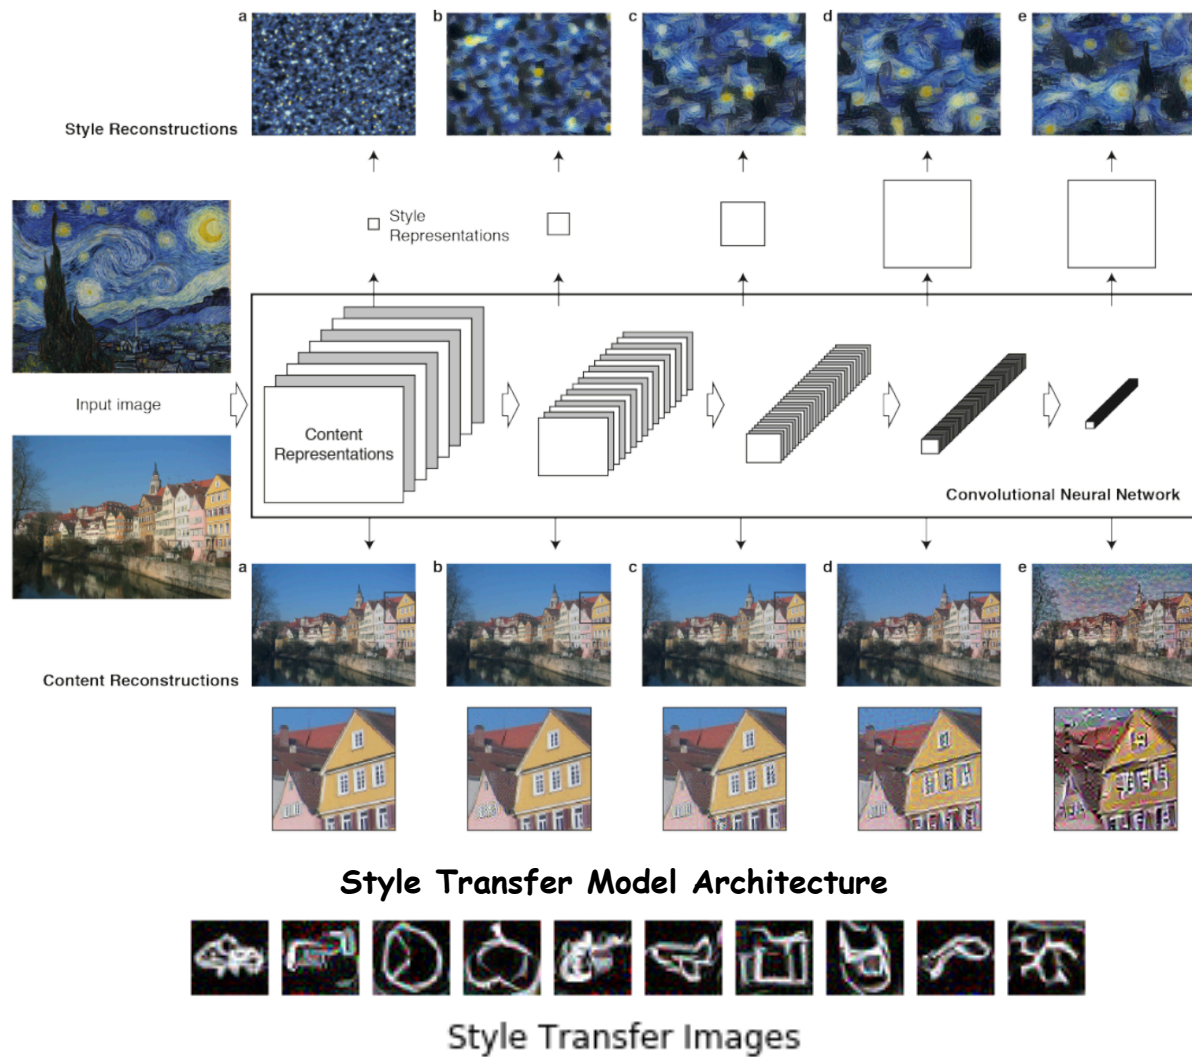
### - 資料前處理

關於資料前處理，我們使用 openCV package 及 ML model 對原始圖檔做轉換，使得原始資料較接近目標域。我們採用以下四種方式：Sobel Edge Detection、Canny Edge Detection、Laplacian Edge Detection 以及 Style Transfer Model。



圖一：原圖及三種邊界偵測方式轉換出來的圖

我們將每一種類轉換出來的圖像，視為新的一種類，以此讓我們的模型擁有不同風格的源域。由於部分資料轉換後並未與目標域資料 (蜘蛛) 相近，因此，除了利用傳統計算機視覺的方式進行風格轉換，我們也參考 A Neural Algorithm of Artistic Style [1] 這篇論文，來實踐機器學習的風格轉換 - 從原圖轉換為手繪風格。我們可以由下圖，看出模型的基本概念和架構以及轉換後的成果。

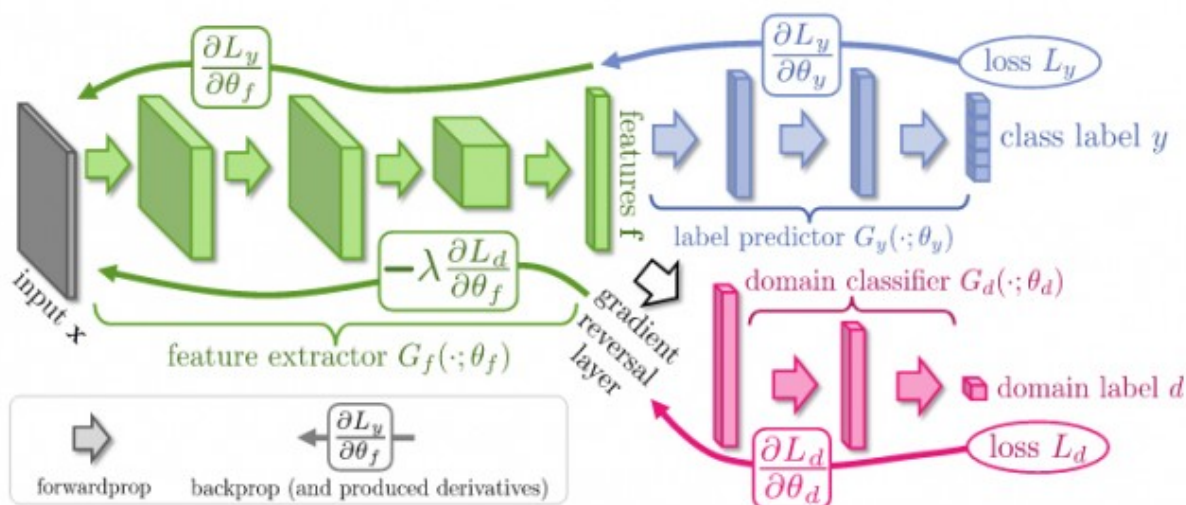


## - 模型簡述

我們主要實作的模型有下面四項，並於其中描述模型特點。

1. Unsupervised Domain Adaptation by Back Propagation(DANN) [2]
2. Maximum Classifier Discrepancy for Unsupervised Domain Adaptation(MCD) [3]
3. Moment Matching for Multi-Source Domain Adaptation(MSDA) [4]
4. VAE (Target Domain) + Pseudo Semi-supervised Learning

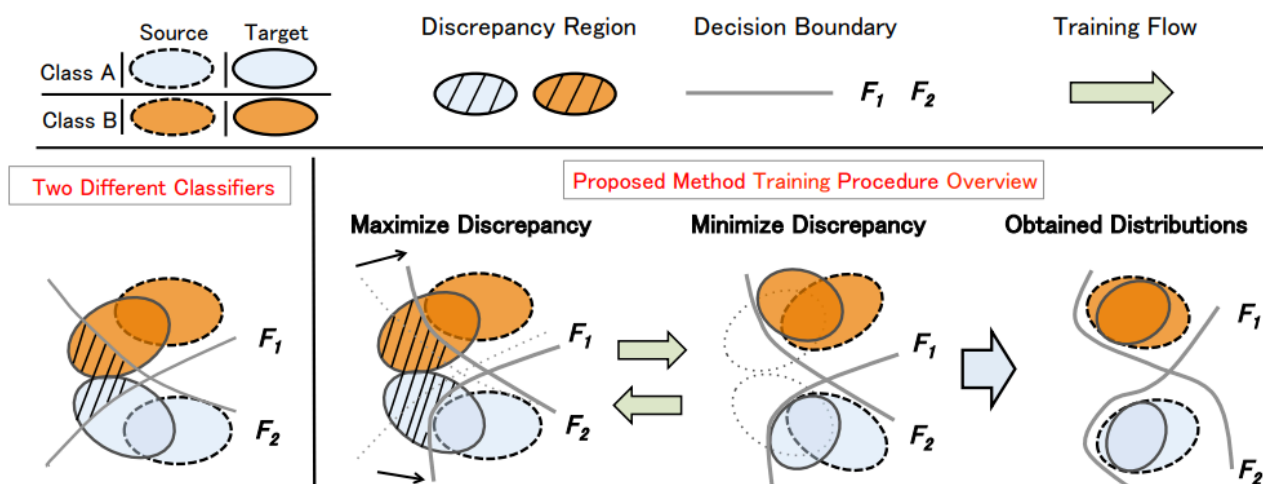
## 1. DANN



為了準確預測不同來源但有潛在共同屬性的資料 (target and source data)，DANN 結合 feature extractor 與兩個分類器，分別為 domain classifier 和 class classifier，原因是若直接使用 source data 訓練出的 class classifier 來分類 target data (無 label 且與 source data 不同 domain) 結果可能會不好，因此 DANN 使用拮抗的概念加上了 domain classifier，在 feature extractor 與 domain classifier 之間加上 gradient reversal layer，如此在反向傳播更新參數時，讓 domain classifier 學習分辨不同 domain 的資料，同時增強 feature extractor 生成出可以混淆 domain classifier 的 features，好讓 feature extractor 騙過 domain classifier，藉此，本篇作者認為 feature extractor 會學習到不同 domain 資料的共同特徵，讓後續的 label predictor 可以順利判斷資料類別。

## 2. MCD

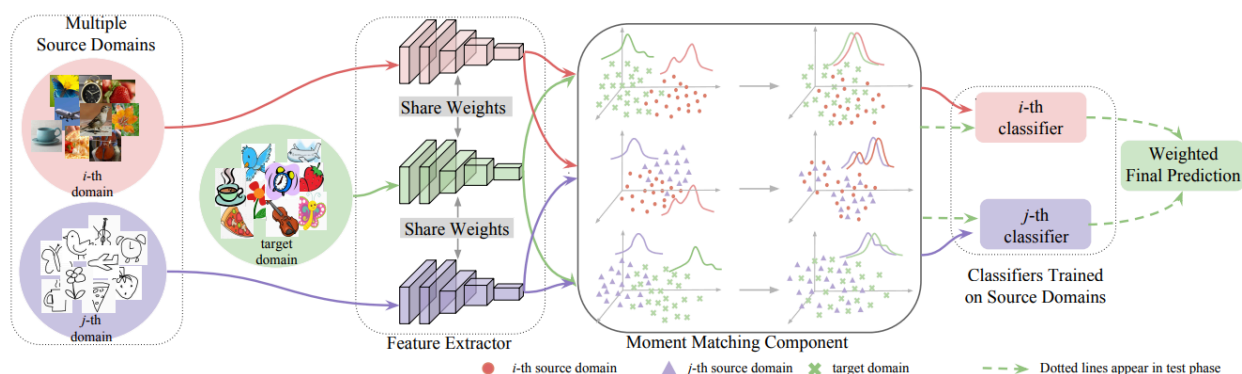
除了 DANN 之外，我們也在網上找到了另一個方法，叫做 Maximum Classifier Discrepancy。以下是架構圖：



其中 F1 及 F2 是兩個 classifier。兩個 classifier 都能準確的分類 source domain 的資料，但是不一定能夠準確分類 target domain 的資料。而且，他們在分類 target domain 的時候錯誤的地方也會不一樣。因此，這個方法就是在說我們要兩個 classifier 在 target domain 上分類資料的結果出現最大的差異，這樣才能將兩個 classifier 分開。而且可以看到上圖中的第三步是要 minimize discrepancy。這麼做的原因是因為我們除了會訓練 classifier 之外，我們還會訓練一個 generator 將原始 domain 的資料轉到另一個 domain。而第二步就是要訓練出一個最好的 generator 來做出能 minimize discrepancy 的 generator。因此，這三步輪流做（一、訓練 classifier。二、訓練 classifier 並最大化他們的分佈差異。三、訓練 generator 來最小化經過 classifier 後的分佈差異。）這三步輪流做之後就能夠將訓練在 source domain 的分類器在 target domain 上做分類。

### 3. MSDA

但是上述的 MCD 也有人將其優化，而這個方法叫 MSDA 並在論文 Moment Matching for multi-source domain adaptation 中提及。與前一篇不同的是，他的 source domain 有很多個，並且會學習所有 source domain 的東西，再放到 target domain。而我們運用在 final project 就是將轉換過的 canny, sobel, style transfer 過後的資料等等變化變成放在整個 model 裡面的 source domain。此外，這個方法還多加有一個概念叫 moment matching。



如上圖，經過 generator 轉換之後，我們希望能將 source 和 target domain 經過轉換之後能模糊他們 feature。因此，我們多了一個 loss function 叫 moment distance。式子如下：

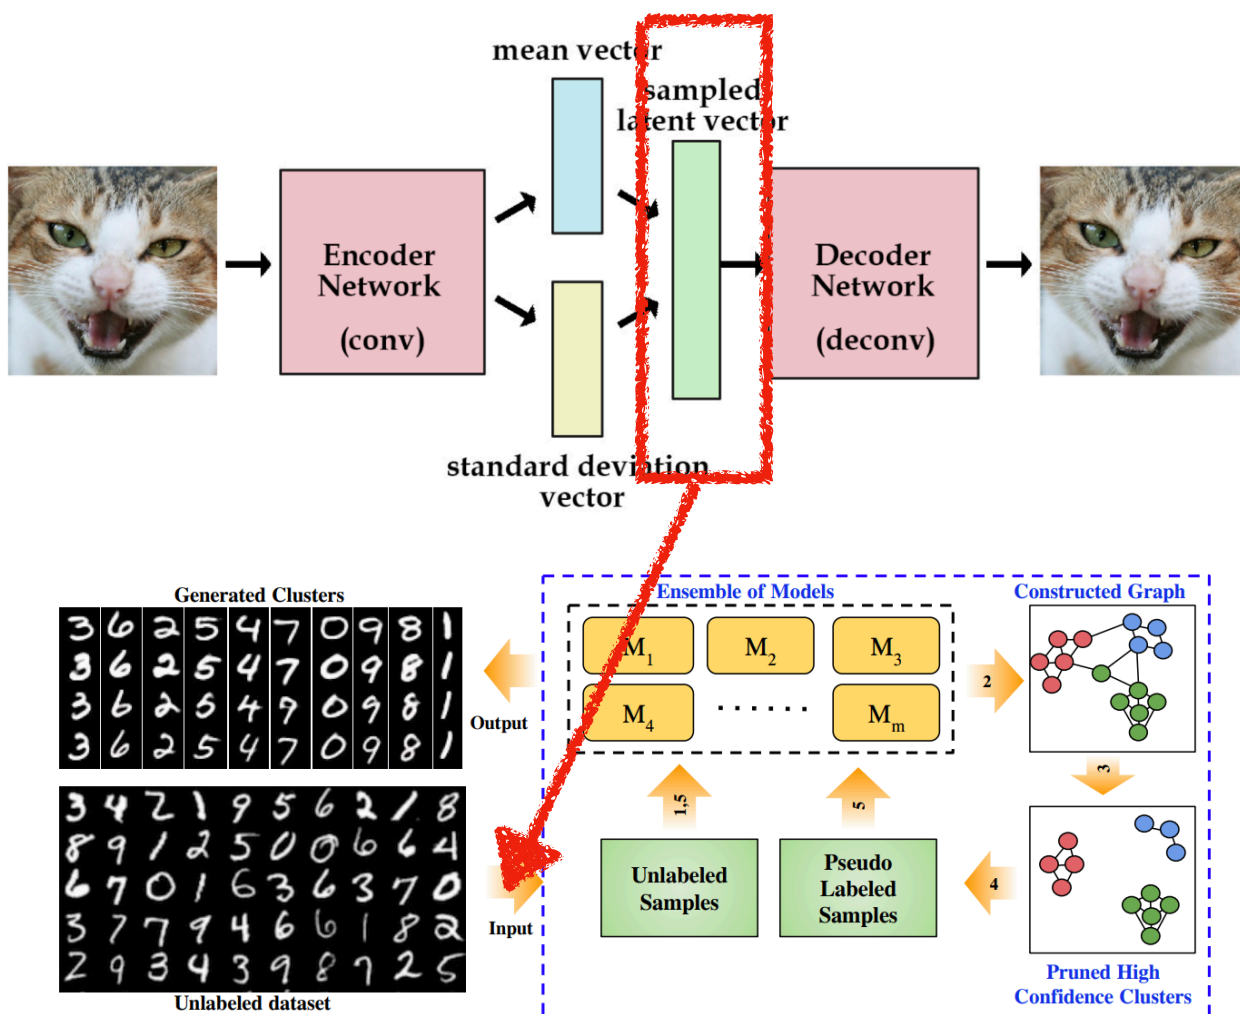
$$MD^2(\mathcal{D}_S, \mathcal{D}_T) = \sum_{k=1}^2 \left( \frac{1}{N} \sum_{i=1}^N \|\mathbb{E}(\mathbf{X}_i^k) - \mathbb{E}(\mathbf{X}_T^k)\|_2 \right. \\ \left. + \binom{N}{2}^{-1} \sum_{i=1}^{N-1} \sum_{j=i+1}^N \|\mathbb{E}(\mathbf{X}_i^k) - \mathbb{E}(\mathbf{X}_j^k)\|_2 \right).$$



並且加入 minimize 的部分並 train 上述的 MCD，便成了 MSDA。而我們最後也是用 MSDA 拿到單一模型的最高分數。

#### 4. VAE + Pseudo Semi-Supervised Learning

我們最後一個所採用的模型是以 Variational Auto-Encoder 來取得 Target Domain 的 Embedding，並以前三個模型所預測出相同的答案為 label 去做 Pseudo Semi-Supervised Learning。整體架構概念如下：(圖源：[5]、[6]) 實際則為 VAE Encoder Part + Fully Connected Classification。




#### - 實驗與討論

在此部分，我們會將其分為兩部分來討論。一為資料本身、二為模型架構的影響。

首先，我們在資料本身上，我們實作四種前處理方式，分別為 Sobel、Canny、Laplacian Edge Detection 及 Style Transfer Model，且以 DANN 為實驗模型，並將分群結果優缺以圖表呈現。我們發現原始資料、Sobel、Canny、Laplacian 學習到的分佈很相近，主要以兩群

分不出來，分別是牛、貓、狗以及貓、飛機、蜘蛛。我們認為這與他們某部分原始圖片就極為相近有關，以及我們雖然我們使用 Edge Detection 來轉換源域，但他們本質還是相似，所以無法有效分類。因此，我們採取 Machine Learning Style Transfer 的方式來轉換圖片，希望改善這些分不太好的群體，但根據我們的實驗，我們只能將貓、飛機、蜘蛛這個群體做改善，其改善主因為若使用 Edge Detection 去轉換蜘蛛這個類別，會將整個圖片切的零零散散 (如下圖示)，但若使用 Style Transfer 則不會，因此得以改善。而牛、貓、狗這群無法改善的原因則因目標域，有些圖片太過相似所以不太能改善 (如下頁圖示)。

	Raw	Sobel	Canny	Laplacian	Style Transfer
Cow	×	×	×	×	×
Bed	✓	✓	✓	✓	✓
Clock	✓	✓	✓	✓	✓
Apple	✓	✓	✓	✓	✓
Cat	×、✓	×、✓	×、✓	×、✓	×
Airplane	✓	✓	✓	✓	✓
Television	✓	✓	✓	✓	✓
Dog	×	×	×	×	×
Dolphin	✓	✓	✓	✓	✓
Spider	✓	✓	✓	✓	✓
Public Score	0.12641	0.54769	0.56894	0.48878	0.42367
Private Score	0.12893	0.55883	0.57083	0.48949	0.43432



表一：前處理方式比較圖

Raw Images




Sobel Images



Canny Images



Laplacian\_ksize3 Images



Style Transfer Images

較為零散

較為連續

實驗比較圖：蜘蛛前處理



CAT



COW



DOG

實驗比較圖：目標域資料相似[7]

接下來，我們將討論各個模型間的差異及其實驗結果，這邊的實驗結果我們會以 Kaggle 分數來當作評量標準，並以 VisDA[8] 的比賽種類區分 - Multi-Source Domain Adaptation 及 Semi-Supervised Domain Adaptation。在 Multi-Source Domain Adaptation 這個分類中，我們從最初的架構 DANN 及不同概念的 MCD 及更延伸的 MSDA。前者 DANN 的目標是最小化域差異，後兩者則為最小化分類器差異。我們並未去實作 DAN 的後面幾代模型 - DDC [9]、DAN [10]，因為我們認為在 MSDA 中已經有採用相關的想法。

	Public Score	Private Score
<b>DANN</b>	0.66356	0.66158
<b>MCD</b>	0.72814	0.72770
<b>MSDA</b>	0.78395	0.78636

在上述模型探討中，我們可以發現以下歸納出幾點已經被考慮到的方向：

1. 領域差異 - 目標域與單源域或多源域。
2. 分類邊界差異 - 目標域與多源域靠近時，分類器邊界應當轉換。

基於上述的整理，我們可以發現一件事情。目前在目標轉移的研究中，並未有論文特別去探討相似多目標域的狀況，我們認為這也許是領域轉移的前進方向，即透過多目標域及多源域找出最佳的域重疊情況。

	Naive CNN	Pretrained
<b>DANN</b>	0.56894	0.66356
<b>MCD</b>	0.72770	0.6324
<b>MSDA</b>	0.78395	0.7204

探討完模型差異，我們接下來要探討的是使用 Pretrained Model 的影響，我們可以從下表中發現，DANN 在使用 Pretrained Model 會得到較高的分數，而 MCD、MSDA 則否。我們可以從 Rethinking ImageNet Pre-training [11] 這篇論文得到一些啟發，使用 Pretrained Model 雖然在整體訓練上會比 train from scratch 快，但在一些較敏感的分類任務並不一定能真的 fine tune 地那麼適當。

接著討論 Semi-Supervised Domain Adaptation，由於我們並未有已知的 label。因此，我們調整成 Pseudo Label Semi-Supervised Domain Adaptation，我們使用上述的各個模型的答案去做偽標籤 (將大家都認為一至的答案當作標籤)。此外，我們透過 VAE 將目標域轉

至潛在空間 (latent space) 中，以期望訓練成果更佳。此部分並未特別與其他 AutoEncoder 方式 - VQVAE、VQVAE 2... 去做比較，因為我們對於此模型的期望為改善原先模型錯誤的地方，達到類似於 Boosting 的方式。

	Public Score	Private Score
PL Semi-Supervised DA	0.85420	0.85262

從實驗數據來看，我們可以發現到正確率上升至 85%。重新檢視可能原因後，發現可能是因為我們是直接採用所產生的 csv 答案當基準，而不是各個種類的機率。這種方法的話，可能會導致 pseudo label 錯誤率過高 (以我們的準確率來分析，大概只能達到 85% 左右的正確率)。

重新總結我們的實驗細項及討論重點，分別為下述：

1. 資料本身 - 前處理方式討論
  - 傳統 Computer Vision 處理方式 - Sobel、Canny、Laplacian
  - ML Based 處理方式 - Style Transfer
2. 模型探討
  - DANN、MCD、MSDA 核心差異及可能研究方向
  - Pretrained Model 討論
  - Pseudo-Label Semi-Supervised Learning

在這一部分的實驗討論中，有些實驗想法很可惜並未去驗證想法是否可行。不過，我們還是可以得到一些結論：1. 以 ML-Based 去做前處理，可以幫助部分資料轉移較佳。2. 以單一源域轉至多源域仍有助於目標域的分類。

## - 結論

試驗多種方法後，我們發現先將 source domain 的資料經過預處理，並將其轉成不同 domain 的資料後，再將他們輸入到 MSDA 裡面做 ensemble 能夠拿到最好的成績。此外，透過反覆實驗，我們發現常常牛、貓跟狗的 label 很容易辨別錯誤。因此，如果我們能夠將這三類東西分類的更佳精準，我們相信正確率一定能再往上突破，甚至超越 90% 都是有可能的。因此，我們雖然做到了 85.4% 的正確率，但如果再嘗試用像 pseudo-semi supervised or pseudo LGB 的方法將那三類分不好的 label 分好的話，我們這個期末專題還是有相當大的突破空間。

## - 組內互評

- R08921A08 廖子毅 100%
- R08942085 陳芃紘 100%
- R08942086 趙達軒 100%



## - 引用

- [1] Gatys, Leon A., Alexander S. Ecker, and Matthias Bethge. "A neural algorithm of artistic style." *arXiv preprint arXiv:1508.06576* (2015).
- [2] Ganin, Yaroslav, and Victor Lempitsky. "Unsupervised domain adaptation by backpropagation." *arXiv preprint arXiv:1409.7495* (2014).
- [3] Saito, Kuniaki, et al. "Maximum classifier discrepancy for unsupervised domain adaptation." *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2018.
- [4] Peng, Xingchao, et al. "Moment matching for multi-source domain adaptation." *Proceedings of the IEEE International Conference on Computer Vision*. 2019.
- [5] VAE(Variational Autoencoder)的原理, <https://www.cnblogs.com/huangshiyu13/p/6209016.html>
- [6] Unsupervised Clustering using Pseudo-semi-supervised Learning
- [7] QuickDraw DataSet, <https://quickdraw.withgoogle.com/data>
- [8] VisDA2019 <https://ai.bu.edu/visda-2019/>
- [9] Tzeng, Eric, et al. "Deep domain confusion: Maximizing for domain invariance." *arXiv preprint arXiv:1412.3474* (2014).
- [10] Long, Mingsheng, et al. "Learning transferable features with deep adaptation networks." *arXiv preprint arXiv:1502.02791* (2015).
- [11] He, Kaiming, Ross Girshick, and Piotr Dollár. "Rethinking imagenet pre-training." *Proceedings of the IEEE International Conference on Computer Vision*. 2019.
- [12] DANN, <https://github.com/fungtion/DANN>
- [13] MCD\_DA, [https://github.com/mil-tokyo/MCD\\_DA](https://github.com/mil-tokyo/MCD_DA)
- [14] MSDA, <http://ai.bu.edu/M3SDA/#code>